Kapak Sayfası

Ders Adı: YZM212 Makine Öğrenmesi
Ödev Başlığı: MLE ile Akıllı Şehir Planlaması
Ad Soyad: Seyyid Abdulbaki Bozkurt
Öğrenci Numarası: 24290381
Tarih: 15.03.2026

Bölüm 1: Teorik Çözümler

Poisson dağılımı varsayımı altında bir dakikadaki araç sayısı k için olasılık kütle fonksiyonu

$$P(K = k \mid \lambda) = \frac{e^{-\lambda}\lambda^k}{k!}$$

şeklindedir. Elimizde bağımsız kabul edilen n adet gözlem $\{k_1, k_2, \dots, k_n\}$ olduğunda likelihood fonksiyonu

$$L(\lambda) = \prod_{i=1}^{n} \frac{e^{-\lambda}\lambda^{k_i}}{k_i!} = e^{-n\lambda}\lambda^{\sum_{i=1}^{n} k_i} \prod_{i=1}^{n} \frac{1}{k_i!}$$

olur.

Bunun doğal logaritması alınırsa log-likelihood fonksiyonu

$$\ell(\lambda) = \log L(\lambda) = -n\lambda + \left(\sum_{i=1}^{n} k_i\right) \log \lambda - \sum_{i=1}^{n} \log(k_i!)$$

olarak yazılır. Burada $\sum \log(k_i!)$ terimi λ parametresine bağlı değildir. Bu yüzden türev alırken sabit olarak kalır.

Şimdi türev alalım:

$$\frac{d\ell(\lambda)}{d\lambda} = -n + \frac{\sum_{i=1}^{n} k_i}{\lambda}$$

MLE elde etmek için türevi sıfıra eşitleriz:

$$-n + \frac{\sum_{i=1}^{n} k_i}{\lambda} = 0$$

$$\frac{\sum_{i=1}^{n} k_i}{\lambda} = n \Rightarrow \sum_{i=1}^{n} k_i = n\lambda \Rightarrow \hat{\lambda}_{MLE} = \frac{1}{n}\sum_{i=1}^{n} k_i$$

Yani Poisson dağılımı için en iyi parametre tahmini, verilerin aritmetik ortalamasıdır.

Bu ödevde kullanılan veri kümesi

$$[12, 15, 10, 8, 14, 11, 13, 16, 9, 12, 11, 14, 10, 15]$$

için toplam değer 170 ve gözlem sayısı 14 olduğundan

$$\hat{\lambda}_{MLE} = \bar{k} = \frac{170}{14} = 12.142857$$

olarak bulunur.

Bölüm 2: Analiz ve Yorumlar

Sayısal MLE

Python tarafında minimize edilen amaç fonksiyonu negatif log-olabilirliktir. Sabit terim çıkarıldığında bu ifade

$$NLL(\lambda) = -\ell(\lambda) = n\lambda - \left(\sum_{i=1}^{n} k_i\right) \log \lambda$$

şeklinde yazılır. `scipy.optimize.minimize` ile yapılan optimizasyon sonucunda sayısal tahmin

$$\hat{\lambda}_{numeric} = 12.142851$$

olarak elde edilmiştir. Analitik sonuç ile sayısal sonuç neredeyse aynıdır. Bu küçük fark, optimizasyon toleransı ve yuvarlamadan kaynaklanır. Yani sayısal çözüm doğru çalışmaktadır.

Grafiklerin Yorumu

Aşağıdaki grafikte gerçek veri histogramı ile Poisson PMF aynı eksende verilmiştir.

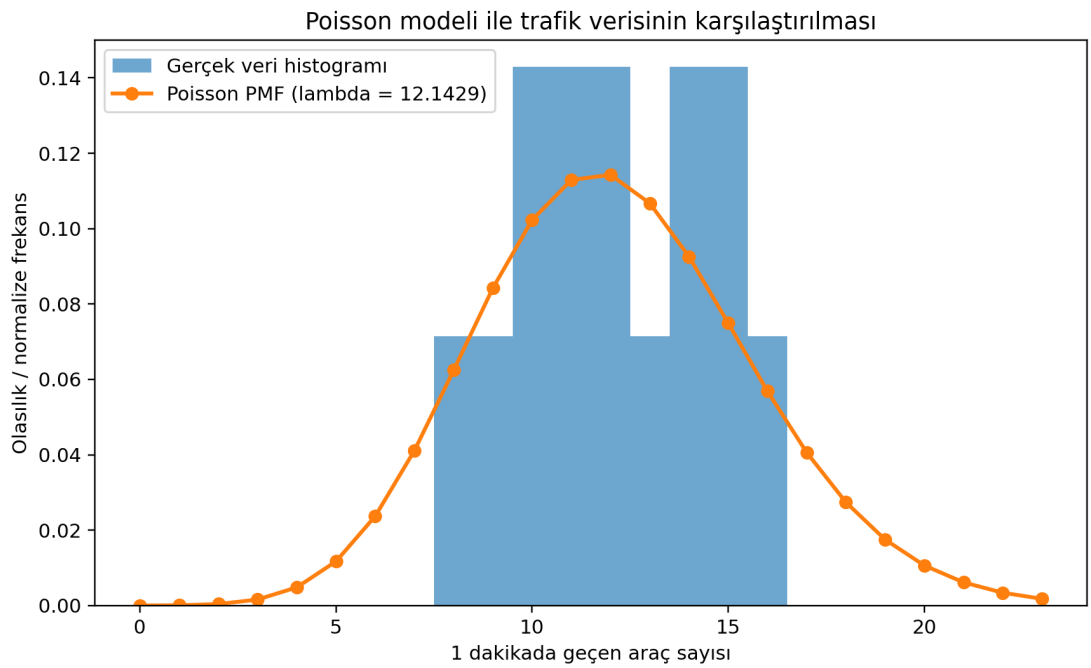

Şekil 1: Orijinal trafik verisi histogramı ve Poisson PMF karşılaştırması.

Histogram 8 ile 16 aralığında yoğunlaşmaktadır. Poisson eğrisi de en yüksek olasılığı bu bant civarında üretmektedir. Veri sayısı düşük olduğu için kusursuz bir örtüşme beklemek yanlış olur, fakat görsel açıdan modelin veri yapısını makul düzeyde yakaladığı söylenebilir. Bu da Poisson varsayımının bu küçük örnek için çalışabilir olduğunu gösterir.

Outlier (Aykırı Değer) Analizi

Veri setine yanlışlıkla 200 araçlık tek bir kayıt eklendiğinde yeni tahmin

$$\hat{\lambda}_{outlier} = 24.666654$$

olmaktadır. Bu, başlangıçtaki parametrenin yaklaşık 2.03 katına çıkması demektir.

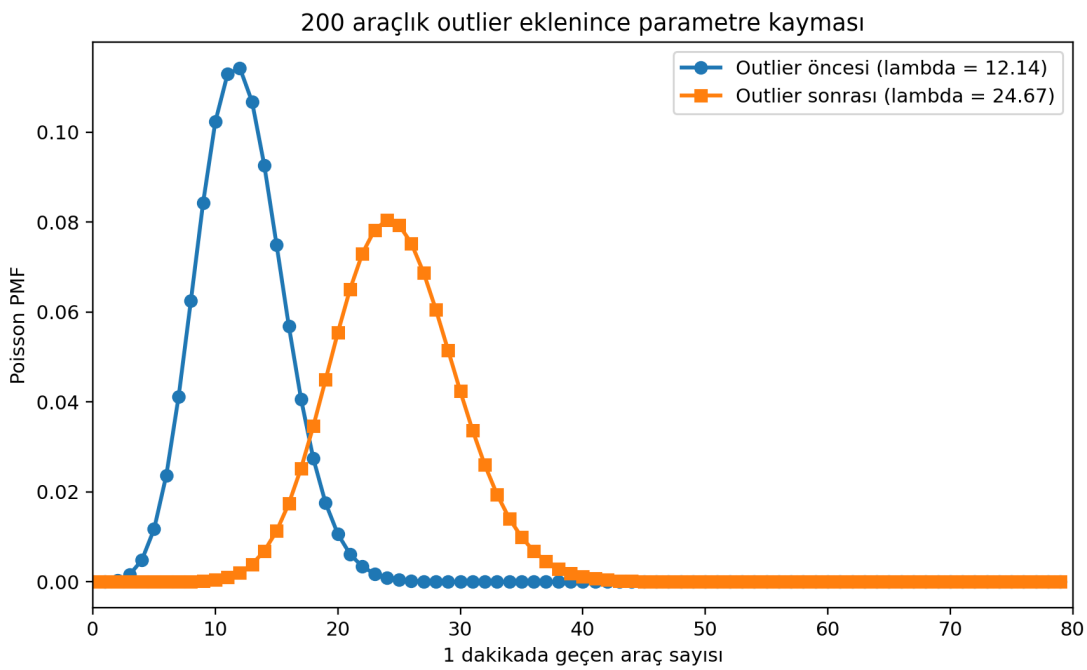

Şekil 2: Outlier öncesi ve sonrası Poisson parametresinin kayması.

MLE yöntemi burada doğrudan ortalamaya bağlı olduğu için uç değerlere hassastır. Tek bir aşırı büyük gözlem bile tahmini ciddi biçimde kaydırır. Gerçek hayatta belediye bu bozuk veriyle karar verirse, trafiği olduğundan çok daha yoğun sanabilir. Bunun sonucu gereksiz yol genişletme kararı, yanlış sinyalizasyon yatırımı, hatalı kapasite tahsisi ve bütçe israfı olabilir. Yani teknik hata sadece matematiksel değil, doğrudan operasyonel ve ekonomik zarara dönüşür.

Bu yüzden saha verisiyle çalışırken veri temizliği, aykırı değer kontrolü ve alternatif sağlam tahmin yöntemleri kritik önemdedir. Aksi halde MLE teorik olarak doğru olsa bile pratikte kırılgan hale gelir.

Kaynakça

1. YZM212 Makine Öğrenmesi 2. Laboratuvar Ödevi PDF metni.
2. Poisson dağılımı ve maksimum olabilirlik yaklaşımına ilişkin temel istatistik formülleri.
3. Referans olarak incelenen GitHub repo yapıları ve çözüm akışları.

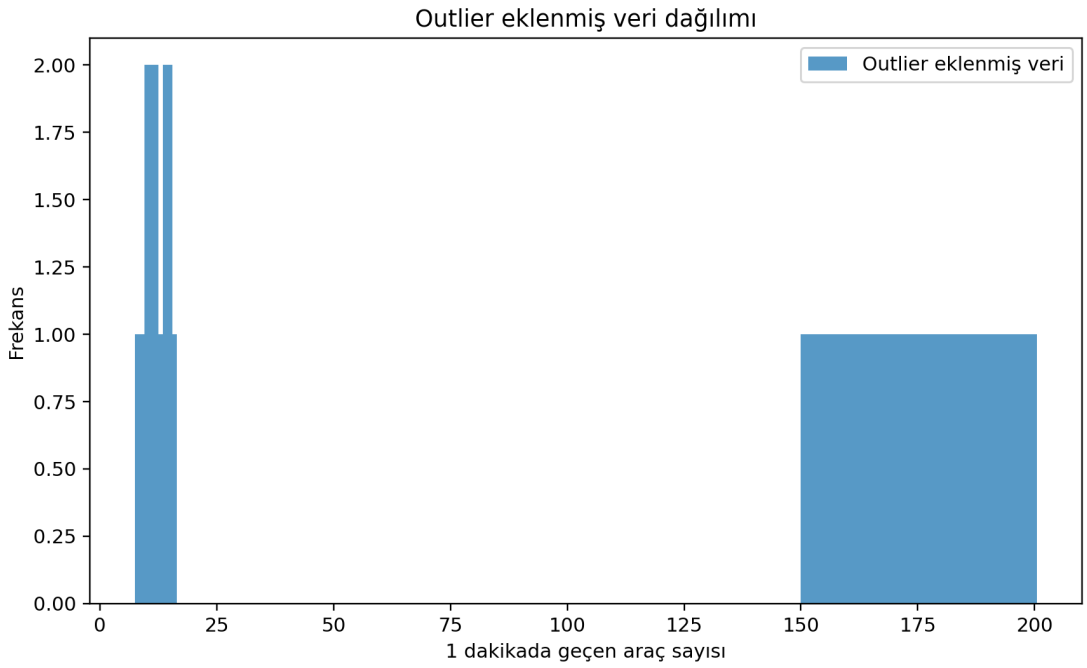

Şekil 3: Outlier eklendiğinde veri dağılımının bozulması.